

Projet Data Science

Analyse nutritionnelle des produits USDA

Caractéristiques, associations entre variables et analyse en composantes
principales

DALINGUESSAN
20 septembre 2026

Table des matières

1	Introduction	2
2	Données et préparation	2
2.1	Description de la base	2
2.2	Valeurs manquantes	2
2.3	Standardisation	2
3	Analyse descriptive	2
4	Associations entre variables	3
5	Analyse en composantes principales	4
5.1	Objectif et méthode	4
5.2	Interprétation des profils	4
6	Application Streamlit	4
7	Limites et améliorations possibles	4
8	Conclusion	5

1 Introduction

Les produits alimentaires présentent des compositions nutritionnelles très variées. L'objectif de ce projet est d'explorer la base nationale de nutriments de l'USDA afin de répondre à trois questions :

1. Quelles sont les principales caractéristiques nutritionnelles des produits ?
2. Quelles associations existent entre les différentes variables ?
3. Peut-on résumer les profils nutritionnels avec une analyse en composantes principales (ACP) ?

L'analyse est complétée par un tableau de bord Streamlit permettant de consulter les résultats de manière interactive.

2 Données et préparation

2.1 Description de la base

Le fichier `USDA_National_Nutrient_DataBase.xlsx` contient une feuille `ABBREV`. Elle comprend 8 790 produits et 53 variables. Chaque ligne correspond à un produit identifié par son nom court et son identifiant USDA. Les variables décrivent notamment l'énergie, les macronutriments, les minéraux, les vitamines, les acides gras et le cholestérol.

Les valeurs nutritionnelles sont généralement exprimées pour 100 g de produit. Les variables de poids de portion et de description textuelle sont conservées pour la description, mais ne sont pas intégrées à l'ACP.

2.2 Valeurs manquantes

La base présente des taux de valeurs manquantes différents selon les nutriments. Les variables de vitamines et de caroténoïdes sont moins renseignées que l'énergie et les macronutriments. Pour l'ACP, seules les variables ayant au moins 70% de valeurs disponibles sont retenues, soit 36 variables.

Les valeurs manquantes de ces variables sont remplacées par leur médiane. Cette stratégie limite l'influence des valeurs extrêmes et permet de conserver les produits dans l'analyse.

2.3 Standardisation

Les unités sont différentes selon les variables : grammes, milligrammes ou microgrammes. Avant l'ACP, chaque variable est donc standardisée selon

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

où $\bar{x}_j$ est la moyenne de la variable j et s_j son écart-type.

3 Analyse descriptive

L'analyse descriptive permet de comparer les ordres de grandeur et la dispersion des principaux nutriments. Le tableau suivant résume les variables retenues pour l'interprétation.

TABLE 1 – Variables nutritionnelles principales

Variable	Interprétation
Energ_Kcal	Énergie en kilocalories pour 100 g
Protein_(g)	Protéines en grammes
Lipid_Tot_(g)	Lipides totaux en grammes
Carbohydrt_(g)	Glucides en grammes
Fiber_TD_(g)	Fibres alimentaires en grammes
Sugar_Tot_(g)	Sucres totaux en grammes
Sodium_(mg)	Sodium en milligrammes
Calcium_(mg)	Calcium en milligrammes

Les distributions sont hétérogènes et souvent asymétriques. Cette observation justifie la standardisation avant l'ACP. Elle indique également que la moyenne seule ne suffit pas à décrire les produits : la médiane et les quantiles doivent être consultés dans le tableau de bord.

4 Associations entre variables

Les associations linéaires sont étudiées avec la corrélation de Pearson :

$$r_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

Une corrélation positive indique que deux variables ont tendance à augmenter ensemble. Une corrélation négative indique qu'une variable augmente lorsque l'autre diminue. Une corrélation ne constitue toutefois pas une preuve de causalité.

Les associations les plus fortes observées sont présentées dans le tableau 2.

TABLE 2 – Associations linéaires les plus fortes

Paire de variables	Corrélation
Vit_A_RAE – Retinol	0,989
Folate_Tot – Folate_DFE	0,983
Folic_Acid – Folate_DFE	0,952
Water – Energ_Kcal	-0,901
Lipid_Tot – FA_Mono	0,885
Folate_Tot – Folic_Acid	0,880
Vit_A_IU – Vit_A_RAE	0,845
Ash – Sodium	0,826

Ces résultats s'expliquent en partie par les relations de définition entre certains indicateurs nutritionnels. Par exemple, plusieurs variables de folates ou de vitamine A mesurent des dimensions proches. La relation négative entre l'eau et l'énergie traduit le fait que les aliments très aqueux sont souvent moins énergétiques pour 100 g.

5 Analyse en composantes principales

5.1 Objectif et méthode

L'ACP transforme les 36 variables nutritionnelles standardisées en axes non corrélés. Chaque axe est une combinaison linéaire des variables initiales. L'objectif n'est pas de supprimer l'information, mais de la résumer dans un espace de dimension plus faible.

Les deux premiers axes expliquent 32,04% de la variance totale : le premier axe explique 20,52% et le deuxième 11,52%. Ce pourcentage montre que le plan factoriel est utile pour visualiser les profils, mais qu'il ne résume pas toute la diversité nutritionnelle.

TABLE 3 – Variance expliquée par les deux premiers axes

Axe	Variance expliquée	Variance cumulée
PC1	20,52%	20,52%
PC2	11,52%	32,04%

5.2 Interprétation des profils

Dans le cercle des corrélations, les variables proches sont positivement associées. Les variables orientées dans des directions opposées sont associées négativement. Une flèche longue et éloignée de l'origine contribue davantage à la construction du plan PC1–PC2.

Dans la projection des produits, deux produits proches dans le plan factoriel ont des profils nutritionnels comparables selon les variables retenues. Les produits situés aux extrêmes des axes correspondent à des profils plus atypiques. Ces extrêmes ne sont pas nécessairement des erreurs : ils peuvent représenter des produits particulièrement riches en énergie, en lipides, en minéraux ou en vitamines.

6 Application Streamlit

L'analyse est disponible sous forme d'une application interactive. Elle propose quatre onglets :

1. compréhension de la structure de la base ;
2. qualité des données et statistiques descriptives ;
3. matrice de corrélation et associations les plus fortes ;
4. ACP, cercle des corrélations et projection des produits.

Le seuil minimal de données disponibles pour retenir une variable dans l'ACP peut être modifié depuis la barre latérale. Cette option permet d'étudier le compromis entre le nombre de variables et la qualité des données.

Lien de démonstration :

<https://usda-nutrition-app-9awedg4cm2qbog5la5j8ci.streamlit.app/>

7 Limites et améliorations possibles

- La base contient des valeurs manquantes, et l'imputation par médiane peut réduire la variabilité observée.

- Les noms des produits ne constituent pas une variable catégorielle structurée ; une analyse par groupes alimentaires nécessiterait un dictionnaire complémentaire.
- Les corrélations étudiées sont linéaires et ne détectent pas toutes les relations non linéaires.
- Les deux premiers axes ne représentent que 32,04% de la variance ; l'interprétation doit donc rester descriptive.

Des prolongements possibles sont une classification des produits dans l'espace factoriel, une analyse par familles alimentaires et une comparaison avec les recommandations nutritionnelles.

8 Conclusion

Cette étude met en évidence une forte diversité nutritionnelle entre les produits USDA. Plusieurs variables sont fortement associées, notamment les indicateurs proches de définition pour les vitamines et les folates. L'ACP permet de résumer les profils et de visualiser les produits similaires ou atypiques, même si les deux premiers axes ne capturent qu'une partie de l'information totale.

Le notebook et l'application Streamlit rendent l'analyse reproductible et interactive. Le code source est disponible sur GitHub : <https://github.com/DALINGUESSAN/usda-nutrition-streamlit>.